

针对黄单胞菌生物防治的噬菌体主动学习工程

iGEM Claremont 2026 — 团队入职培训

核心工程师: Alex Chen · 导师: J. Cesar Ignacio-Espinoza · 学术顾问: Ran Libeskind-Hadas

2026 年 5 月

第 0 部分——路线图

三句话总结

- 针对 *Xanthomonas campestris* pv. *campestris* 的噬菌体 RBP 工程的**闭环主动学习**系统。
- **Module 00-07 已全部完成**（计算部分）；Module 08（湿实验室数据）大约 6 月 1 日启动。
- 首个 Boltz-2 结果 rbp_01（712 aa）× TonB: **ipTM = 0.365, chain_A_ptm = 0.808**。
- BALD 在**不到 1 秒**内推荐下一轮 4 个 variant + 1 个随机对照。

* 目标: Best Agriculture Project · Best Model · Best Composite Part. *

路线图

- 1 **科学背景**——黄单胞菌、噬菌体宿主范围、数据稀缺问题。[湿实验室] [PI]
- 2 **流程架构**——Module 00-08, 数据约定。[干实验室] [PI]
- 3 **ML 核心**——深度集成、BALD、代码与输出样本。[干实验室] [PI]
- 4 **当前 Boltz-2 结果**——0.365 ipTM 意味着什么。全员
- 5 **48 小时循环**——干湿对接、ELISA、敲除。全员
- 6 **复现与演示**——快速开始、测试、Laguna。[干实验室] [湿实验室]
- 7 **风险、决策与请求** [PI]
- 8 **参考文献与附录** 全员

如何阅读本演示

每个章节标题后的标签告诉你这部分给谁看：

- **[湿实验室]** ——生物学动机、实验流程、需要执行的对接。
- **[干实验室]** ——代码、算法、文件约定、可重现性。
- **[PI]** ——整体框架、需要决策的事项、风险。

未标记的部分面向全员。

推荐分段 (presenter cuts)

- **30 分钟湿实验室入门:** slide 1-4, 7-12, 17-22 (模块速览), 37-44 (48 小时循环与实验流程)。
- **45 分钟 PI / 顾问简报:** slide 1-4, 5-12 (科学背景), 13-14, 23, 28-32 (ML 核心), 33-36 (Boltz-2), 51-55 (风险与决策), 56 (交付物)。
- **90 分钟全员深入:** 全部 slide。

演示 (约 15 分钟) 独立于此 deck, 可在第 48 张后或最后运行 (见 DEMO.md)。

第 1 部分——科学背景 · [湿实验室] [PI]

本部分关键术语

- **噬菌体 (phage) / 裂解性噬菌体 (lytic phage)** ——感染细菌的病毒；裂解性 = 复制后让宿主细胞破裂（我们要的那种）。
- **RBP (受体结合蛋白)** ——噬菌体尾部的蛋白，与细菌表面某个特定受体结合。这是” 钥匙-锁” 的步骤。
- **致病变种 (pathovar, pv.)** ——植物病原菌中按” 侵染哪种植物” 细分的株群。
- **AUC** ——0.5（随机）到 1.0（完美）的单一分数，衡量二分类质量。
- **BLAST** ——序列相似性搜索。找不到序列已分歧到字母不再相似的同源蛋白。
- **HMM (隐马尔可夫模型)** ——学习蛋白质家族” 模式” 的序列搜索方法，能抓住 BLAST 漏掉的同源蛋白。
- **TonB / ExbB / ExbD1** ——细菌外膜上的能量耦合转运复合体；phiL7 的入口 (Hung 2003)。

Xanthomonas ——是什么、为何重要

- 植物病原性 γ -变形菌属；侵染 >400 种宿主植物 (Ryan 2011, Nat Rev Microbiol)。
- 加州相关致病变种：
 - **Xcc** ——十字花科黑腐病 (甘蓝、西兰花、羽衣甘蓝)。
 - *X. citri* subsp. *citri* ——柑橘溃疡病。
 - *X. perforans* / *X. euvesicatoria* ——番茄细菌斑病。
- 当前防治依赖**铜制剂**；耐铜性已广泛出现 (Aiello 2019, Plant Dis)。
- 田间试验显示噬菌体防治可达铜制剂效果 (Iriarte 2018; Holtappels 2022)。

噬菌体生物防治——宿主范围问题

- 噬菌体**宿主特异性强**——既是优点（无脱靶微生物）也是缺点（每个菌株需要对应的噬菌体）。
- 预测哪种噬菌体能感染哪种细菌仍不可靠：
 - **PhageHostLearn** (Boeckaerts 2024, Nat Commun) **菌种内 AUC 0.82**。
 - **跨菌属 AUC 降至 0.67-0.70** (PAML benchmark, Mutalik 2025)。
- 瓶颈：有标签的（噬菌体，宿主）相互作用数据稀缺、昂贵、物种受限。

我们的参考骨架

宿主	Xcc ATCC 33913	NCBI: GCF_000007145.1
噬菌体	phiL7	NCBI: EU717894
来源	da Silva 2002 (Nature); Lee 2009 (AEM)	

- 干实验室使用上述公共参考。
- **湿实验室从加州十字花科作物自分离**——绕过 4 个月的 USDA APHIS PPQ-526 许可证 (PI 协商, 2026-05-07)。

phiL7 受体系统——Hung 2003

Hung, C.-H. 等 (2003) BBRC 302:878-884, PMID 12646254。

- phiL7 通过 **TonB-ExbB-ExbD1** 复合体进入 Xcc（能量耦合的外膜转运）。
- Tn5 突变 + 互补实验：**TonB、ExbB、ExbD1 必需**。
- ΔexbD2 （菌株 CH620）保留完全敏感性 → **ExbD2 不是必需**。

免费的阴性对照。 2026 年 5 月文献核查修正了早先错误将 ExbD2 列为必需的引用。构建 ΔexbD2 与 ΔtonB / ΔexbB / ΔexbD1 平行——可验证整个敲除系统： ΔexbD2 应当仍允许感染。

phiL7 的 RBP ——Lee 2009 与我们的 HMM 重新发现

Lee, C.N. 等 (2009) AEM 75:7828 ——phiL7 基因组论文。

- Lee 2009 **主动搜索**了 OP1 tail fiber (ORF25) 的同源物，**通过序列相似性找不到**：“We were unable to identify a homolog of the OP1 tail fiber protein (ORF25)…”
- p20 (1105 aa) 被建议与宿主范围相关；论文中没有任何蛋白被命名为” tail spike”。
- 我们的 **rbp_01 (712 aa)** 来自 PhageRBPdetect 的 Tail_spike_N HMM ——一种结构 profile 方法，能找到序列已分歧到 BLAST 找不到的蛋白。
- 与 Lee 2009 不矛盾——这是用更敏感工具的互补发现。

数据稀缺瓶颈

- 我们的系统**只有 1 个**实验确认的（噬菌体，宿主）相互作用：phiL7 × Xcc。
- 相互作用矩阵（Module 01）有 2,236 个文献整理对——但没有定量结合亲和数据。
- 对于 712 aa 蛋白，变种空间为 20^{712} ——远超任何湿实验预算。
- **需要一种让每次昂贵 ELISA 测量都尽可能多产生信息的学习策略。**

为什么主动学习是正确的框架

- **主动学习 (AL)**: 模型通过最大化预期信息增益来选择下一个训练点 (Lindley 1956; Settles 2009)。
- 在相邻领域已证明 $2-5\times$ 优于随机选择:
 - **Hie 2024** (Nat Biotechnol) —— ESM-1b/1v + AL 进行抗体亲和成熟 (每个抗体约 20 个 variant)。
 - **Yang 2025 ALDE** (Nat Commun) —— DNN 集成 + **Thompson 采样** (不是 BALD) 做酶定向进化, 产率 $12\% \rightarrow 93\%$, 2 轮 wet lab。
- **没有人将其应用于噬菌体 RBP $\times$ 细菌受体**。这正是我们的方法学贡献。

对应到 iGEM 的赛道

赛道	我们的交付物
Best Agriculture Project	针对 Xcc 的噬菌体生物防治流程
Best Model	闭环 AL + UQ + 因果验证
Best Composite Part	注册的 RBP-His6 表达库

外加：自分离的 *Xanthomonas* + 噬菌体菌株，测序并存入 NCBI。

第 2 部分——流程架构 · [干实验室] [PI]

本部分关键术语

- **模块 (Module)** ——仓库里以数字编号的子目录 (00_…到 08_…)。每个模块只做一件事；产出供下一个模块消费。
- **ORF (开放阅读框)** ——DNA 上编码单个蛋白的一段 (起始密码子 → 终止密码子)。
- **gitignored** ——列在 .gitignore 里、git 不跟踪。大体积二进制文件 (基因组、模型权重) 被排除，但在 MANIFEST.csv 里记下，保持可重现。
- **MANIFEST.csv** ——每个文件夹的”账本” (文件名 · SHA-256 · 大小 · 记录数)，让 gitignore 的产物可验证。
- **Conda 环境**——项目专用 Python 安装，每个库版本固定。conda activate igem2026。
- **Notebook 优先**——探索代码先写 .ipynb；稳定后冻结为 .py。
- **双语注释**——仓库内每条代码注释都同时写英文和中文。


三层架构

第 0 层——先验	Boltz-2 ipTM、ESM-2、PLM-interact (可选)
第 1 层——AL 循环	集成 → BALD → ELISA → 重训
第 2 层——因果性	ΔtonB / ΔexbB / ΔexbD1 敲除

结合（第 1 层）是感染的必要但不充分条件（Farquharson 2021）。第 2 层将受体特异性结合与防御系统贡献解耦。

Pipeline 一览——Module 00 → 08

iGEM Claremont 2026 — Active-Learning Pipeline / 主动学习流程



颜色编码：数据（蓝）· 特征（黄）· ML（绿）· 湿实验室（粉）。

数据约定

Module N — data contract / 模块内数据流约定



outputs/ → Module (N+1) inputs/ (READ-ONLY POINTER, no copy)

■ inputs/ = 指向上游 outputs 的指针（只读）。

■ processes/ = 唯一写代码的地方。

■ outputs/ = 经典产物：MANIFEST.csv（大文件 gitignore）

Notebook 优先 + 双语注释 (CLAUDE.md)

- 新代码先以 **Jupyter notebook** 形式编写 (`<NN>_<short_name>.ipynb`)。
- 当 notebook (a) 能端到端运行 (b) 通过验证 cell → **冻结为 .py**。
- **双语注释**为强制规范——简短注释 `# English / 中文` 同行。
- Module 07 例外——生产流程，从第一天就写 `.py`。
- `nbstripout` 全仓库启用，notebook 输出不会污染 git diff。

Module 00 ——原始数据

- **777 个噬菌体 + 34 个细菌完整基因组** (NCBI)。
- 基因组二进制 **gitignore** (约 630 MB); 可通过下列命令重新下载:
 - `python 00_raw_data/processes/fetch_phages.py`
 - `python 00_raw_data/processes/fetch_bacteria.py`
- **MANIFEST.csv** 提供每个基因组的 SHA-256 + 大小, 可重现。
- 标准参考对: **EU717894.1.fna** (phiL7) + **GCF_000007145.1.fna** (Xcc)。

Module 01 ——Ground Truth 相互作用矩阵

01_data_ground_truth/outputs/interaction_matrix.csv ——前 4 行:

phage_acc	host_acc	label	source	notes
EU717894.1	GCF_000007145.1	1	literature_curated	Hung 2003 (受体); Lee 2009 (基因组)
NC_054459.1	NZ_CP150073	1	literature_curated	X. oryzae pv. oryzae
ON758385.1	—	1	literature_curated	Xanthomonas sp.
ON711490.1	—	1	literature_curated	Xcc XC114

- 2,236 对 (315 阳性 + 1,921 阴性 + 1 ground truth)。
- 22/22 测试通过。

Module 02 ——注释

- **噬菌体**：PHANOTATE (McNair 2019) ——动态规划处理重叠 ORF。
- **细菌**：pyrodigal 绑定 Prodigal (Hyatt 2010)。
- **绝不互换**。Prodigal 假设 ORF 不重叠 → 丢失约 10-15 % 噬菌体基因。
- 可选第二轮：pharokka (PHROG / VFDB / CARD) 做功能分类。

基因组	工具	检出 ORF 数
phiL7 (EU717894.1)	PHANOTATE	80
Xcc (GCF_000007145.1)	pyrodigal	4,344

Module 03 ——RBP 识别 (PhageRBPdetect, Boeckaerts 2022)

03_rbp_identification/outputs/EU717894.1_rbp_candidates.csv ——80 个 ORF 中的 top 3:

orf_id	length_aa	hmm_score	hmm_match	combined_score	rank
EU717894.1_orf_00001	712	342.0	unknown_C54	1.000	1
EU717894.1_orf_00021	918	235.1	unknown_C112	1.000	2
EU717894.1_orf_00003	224	56.7	unknown_C294	1.000	3

- **rbp_01** (= orf_00001, 712 aa, HMM score 342) ——Cycle 0 主要目标。
- 命中 Tail_spike_N HMM ——正是 Lee 2009 用 BLAST 找不到的那种蛋白。
- 25+ 测试通过 (本地需 hmmpress, 否则 2 个会失败)。

Module 04 ——蛋白嵌入 (ESM-2, Lin 2023)

- ESM-2 = 在约 65 M 蛋白序列上预训练的 masked language model (UniRef50/90)。
- 残基级嵌入 mean-pooling → 序列级向量。

变体	维度	运行位置
esm2_t6_8M_UR50D	320	本地 CPU (概念验证, 当前 outputs)
esm2_t33_650M_UR50D	1280	Laguna A100 / L40S (生产目标)
esm2_t36_3B_UR50D	2560	仅 Laguna (最终基准)

可选层: PLM-interact (Liu 2025) ——在人类 PPI 上 fine-tune 的 ESM-2。迁移到 mouse / fly / worm / yeast / E. coli PPI 后 AUPR +16-28 %。**尚未在噬菌体-细菌上测试**——我们可能是第一个。

Module 05 ——结构预测 (Boltz-2 + AF3)

- **Boltz-2** (Passaro 2025) ——预测复合体 3D 结构 + ipTM 界面信心分数。
- **AF3** (Abramson 2024) ——更高质量静态结构；支持 trimer。

关键警语——Boltz-2 的 affinity head 只支持小分子。训练数据来自 PubChem / ChEMBL / BindingDB。对**蛋白-蛋白对**（如 RBP × TonB）affinity head 输出 **NaN**。使用 **ipTM** 作为结构信心 proxy，**不是**定量亲和力。

第 3 部分——ML 核心 · [干实验室] [PI]

本部分关键术语——神经网络基础

- **神经网络 (neural network)** ——一串数学函数堆成“层”，把一个数字向量变成另一个。训练时调整每层里的数字，让训练集上的损失最小。
- **MLP (多层感知机)** ——最简单的结构：若干全连接层，每两层之间夹一个非线性。Module 06 用的就是它。
- **层 / 隐藏层** ——“层” = 一次矩阵乘法 + 偏置。**隐藏层**就是输出不直接作为最终预测的那种层，是网络学到的中间表示。我们的 MLP 有 3 个隐藏层，宽 256 / 256 / 128。
- **ReLU** ——把正数保留、负数变零。没有非线性，叠多层在数学上塌缩成一条直线。
- **Dropout** ——训练每一步随机关掉一些连接，迫使信息分散，避免死记训练集。
- **高斯 (Gaussian)** ——钟形分布，由均值（中心）和 σ （宽度）描述。模型每个输入输出 (μ, σ) 。
- **NLL 损失** ——对真实答案给低概率会惩罚多。“错了承认不确定”比“错了还自信”代价小。

本部分关键术语——不确定性 + 主动学习

- **深度集成 (deep ensemble)** ——同一架构、不同随机初始化，独立训练多次。数据充分处成员收敛、数据稀疏处成员分歧。
- **Epistemic vs aleatoric** ——epistemic = 模型无知，可通过更多数据缩小；aleatoric = 不可消除的测量噪声（如 ELISA 加样差异）。BALD 只瞄准 epistemic。
- **校准 / ECE** ——“90 % 置信区间”是不是真有 90 % 的概率覆盖真值？Expected Calibration Error 量化这个偏差。
- **互信息 (mutual information)** ——“知道 X 能告诉我多少关于 Y 的信息”。独立则为零。
- **BALD** ——选”测了之后能给模型参数带来最多互信息”的实验。
- **采集函数 (acquisition function)** ——从候选池里挑下一个该测的样本的规则。BALD 是一种；ALDE 用的 Thompson 采样是另一种。

Module 06 ——深度集成用于预测不确定性

- **Lakshminarayanan 2017** (NeurIPS) ——5 个 MLP，独立训练，输出预测均值 + 不确定性。
- 每个成员通过 Gaussian NLL loss 输出高斯分布 (μ_k, σ_k^2) 。

为什么用 deep ensemble? - 校准性优于 MC Dropout (Ovadia 2019)。- 可扩展到 ESM-2 的 1280 维输入 (GP 做不到)。

Greenman 2025 核查: ” 没有单一最佳 UQ 方法” (蛋白工程基准下)。集成通常 accuracy 最高但 calibration 最差。我们选集成的理由: (a) 可扩展性, (b) ALDE 的先例, (c) ECE 可以用 temperature scaling 修正。

ensemble.py ——单成员预测（代码片段）

```
def forward(self, x: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor]:
    """
    Returns (mean, sigma) — both shape (batch,).
    返回 (均值, 标准差), 各形状为 (batch,)。
    """
    h = self.net(x)
    mean = self.head_mean(h).squeeze(-1)
    # Clamp log_sigma to [-7, 7] for numerical stability
    # 将 log_sigma 截断到 [-7, 7] 防止数值爆炸
    log_sigma = self.head_log_sigma(h).squeeze(-1).clamp(-7.0, 7.0)
    sigma = torch.exp(log_sigma)
    return mean, sigma
```

来源: 06_uncertainty_model/processes/ensemble.py:57-68。

Epistemic vs Aleatoric ——关键分解

对 K 成员的高斯集成，总预测方差分解为：

$$\sigma_{\text{total}}^2(x) = \underbrace{\text{Var}_k[\mu_k(x)]}_{\text{epistemic (可约)}} + \underbrace{\mathbb{E}_k[\sigma_k^2(x)]}_{\text{aleatoric (噪声)}}$$

- **Epistemic** = 模型不知道的部分 → 数据越多越小 → **BALD** 的目标。
- **Aleatoric** = 测量 / 实验噪声 → 本质上不可约。

predictions.csv 同时导出: std (总) 和 epistemic_std (BALD 输入)。


Module 06 输出——Cycle 0（合成数据）

06_uncertainty_model/outputs/cycle_0/predictions.csv ——部分行：

rbp_id	receptor_id	predicted_score	std	epistemic_std
rbp_00	rec_00	4.872	0.736	0.125
rbp_00	rec_01	4.959	0.755	0.114
rbp_01	rec_02	5.128	0.726	0.190
rbp_01	rec_03	5.094	0.715	0.049
rbp_07	rec_02	5.177	0.721	0.218

- 80 个 (RBP × receptor) 对。
- epistemic_std 在候选池中范围 0.04-0.22。
- model_version = aa99d51_cycle_0 (git SHA + 循环)。


Calibration 校准图——Cycle 0 (合成数据)



可信区间覆盖率 vs 观察值。良好校准 = 点落在对角线上。合成数据下接近对角线——Cycle 0 ELISA 后将产生真正可信的版本。

Module 07 ——BALD 直观示意

BALD selection intuition — pick where the model disagrees most
BALD 选取直观：选模型成员分歧最大的点



BALD 数学（回归延伸）

原始版本 (Houlsby 2011, GP 分类):

$$\text{BALD}(x) = I(y; \theta \mid x, D) = H[y \mid x, D] - \mathbb{E}_{\theta \sim p(\theta \mid D)}[H[y \mid x, \theta]]$$

对高斯深度集成 + 回归目标:

$$\text{BALD}(x) \approx \text{Var}_k[\mu_k(x)] \implies \text{score} = \text{epistemic_std}$$

延伸说明。 Houlsby 2011 原始论文应用于高斯过程分类器。把信息论目标延伸到深度集成回归是合理的，但属于我们的延伸——**不是**原文直接引用。学术场合呈现时应注明这一点。

bald.py ——bald_score() + select_batch()

```
def bald_score(epistemic_std: np.ndarray) -> np.ndarray:
    """BALD score = epistemic_std (与 epistemic 方差单调等价)."""
    if np.any(epistemic_std < 0):
        raise ValueError("epistemic_std must be non-negative; got negatives.")
    return epistemic_std.copy()

# select_batch() 内部: 按 BALD 分数降序排名, 取 top-K
ranked = pool.sort_values(bald_col, ascending=False).reset_index(drop=True)
ranked["bald_rank"] = ranked.index + 1
bald_picks = ranked.iloc[:n_bald].copy()
bald_picks["selection_reason"] = [f"bald_top_{i+1}" for i in range(len(bald_picks))]

# 随机对照: 从未选中的 BALD top-K 之外抽样
remaining = ranked[~ranked.index.isin(set(bald_picks.index))]
random_picks = ranked.loc[_random.Random(seed).sample(list(remaining.index), k=n_random)]
random_picks["selection_reason"] = "random_control"
```

来源: 07_acquisition_function/processes/bald.py:38-135。

Module 07 输出——Cycle 1 推荐

07_acquisition_function/outputs/cycle_1/recommendations.csv:

rbp_id	receptor_id	predicted_score	epistemic_std	bald_rank	selection_reason
rbp_07	rec_02	5.177	0.218	1	bald_top_1
rbp_03	rec_01	4.810	0.197	2	bald_top_2
rbp_05	rec_02	4.906	0.196	3	bald_top_3
rbp_01	rec_02	5.128	0.190	4	bald_top_4
rbp_03	rec_03	5.128	0.127	19	random_control

- 4 个 BALD pick + 1 个随机对照 (Hie 2024 对照臂设计)。
- 这是**合成占位数据**。真正的 Cycle 1 = rbp_01 variants × TonB (Cycle 0 ELISA 后)。

ALDE 警语——Yang 2025 不验证 BALD

- **Yang 2025 ALDE** (Nat Commun) 是最接近的公开工作——AL + DNN 集成 + 蛋白工程。
- 但是：ALDE 用的是 **Thompson 采样** 作为采集函数，**one-hot encoding** 作为特征。不是 BALD，不是 ESM-2。
- 因此 ALDE 验证的是：“AL + UQ + DNN 集成在蛋白工程中可行”。
- BALD 本身仍需另立引用链 (Houlsby 2011 + 我们的延伸)。

第 4 部分——当前 Boltz-2 结果

本部分关键术语

- **结构预测 (structure prediction)** ——给一段氨基酸序列 (或两段), 预测蛋白质的 3D 形状——每个原子在哪。把数月的 X 射线晶体学换成“足够好”的起点。
- **PDB 文件**——原子级 3D 结构的标准纯文本格式 (每行一个原子)。用 PyMOL (免费) 或 ChimeraX (免费) 打开。
- **ipTM** ——interface predicted TM-score (0-1)。对两条链如何对接的信心。 ≥ 0.6 可信; 0.4-0.6 模糊; < 0.4 模型基本在猜。
- **chain pTM** ——单条链自己的 TM-score。单体结构是否可信, 独立于对接。我们的 `chain_A_ptm = 0.808` 说明 `rbp_01` 单体可信。
- **PAE (预测对齐误差)** ——二维矩阵。 $[i, j]$ = “对齐到残基 i 时, 残基 j 的位置预计偏差多少 Å”。非对角块低值 = 界面信心高。
- **pLDDT** ——逐残基的局部骨架几何信心。高 = 模型对该残基的局部位置很确定。

我们跑了什么 (job 59986)

Chain A	rbp_01 (712 aa 尾刺候选, EU717894.1)
Chain B	TonB (604 aa, GCF_000007145.1)
GPU	NVIDIA L40S (CARC Laguna)
运行时间	约 3 分钟


历史注：早先一次 (job 59949) 用错了蛋白——85 aa P25 ORF 被误标为 rbp_01。 **job 59986** 用的是正确的 **712 aa rbp_01** (来自 03_rbp_identification/outputs/EU717894.1_rbp_sequences.faa)。

三个关键数字

指标	数值	解读
interface_ipTM	0.365	低——模型对如何对接不确定。
chain_A_ptm	0.808	高——rbp_01 单体结构良好预测。
confidence_score	0.683	中等的总体复合体质量。

低 ipTM **不是失败**——它定义了实验。这种不确定性正是 ELISA + 主动学习循环要回答的问题。高 chain A ptm 说明 rbp_01 结构约束良好 → 是 variant design 的可靠基础。

PAE 热图——界面块



Boltz-2 输出位置

```
05_structure_prediction/outputs/boltz2/  
EU717894.1_rbp_01__GCF_000007145.1_tonB/
```

目录内：

- `affinity.json` —— `interface_ipTM`、`chain_A_ptm`、`confidence_score`。
- `boltz_results_.../predictions/.../*.pdb` —— 完整原子坐标（PyMOL / ChimeraX 打开）。
- `pae_*.npz` —— PAE 矩阵。
- `plddt_*.npz` —— 逐残基 pLDDT（范围 0.30-0.98，均值 0.76）。

完整路径见 `docs/planning/PI_briefing_2026-05-11.md`（无省略号）。

Boltz-2 提醒： `predicted_dG = null`，因 `affinity head` 仅支持小分子。


第 5 部分——48 小时循环 · [湿实验室] [干实验室]

本部分关键术语

- **Gibson 组装**——一管反应 (5′ 外切酶 + 聚合酶 + 连接酶)，把有重叠序列的 DNA 片段连成环状质粒。Cycle 0 用它克隆。
- **SDM (定点突变)**——在已有质粒上做单点改动 (例如 K450A)。~\$50 / 4 天; Cycle 1+ 用它。
- **BL21(DE3) / pET-28a / IPTG**——大肠杆菌表达菌株 + 质粒骨架 + 启动基因表达的诱导剂。
- **His6 + Ni-NTA**——N 端的 6 个组氨酸结合镍柱 → 一步纯化 (IMAC)。
- **SDS-PAGE**——凝胶电泳按大小分离蛋白; 查纯度。
- **EC50 / 4PL 拟合**——把结合曲线拟合成四参数 logistic; EC50 = 信号达半值最大时的浓度, 是模型的目标变量。
- **噬斑 / PFU**——细菌草坪上一个清亮斑 = 一个有侵染力的噬菌体; PFU/mL = 储液浓度。
- **pK18mobsacB / sacB 反选**——在 *Xanthomonas* 里做无标记敲除的“自杀”质粒; sacB 使细胞在蔗糖里死, 所以可筛出丢掉质粒 (第二次重组) 的克隆。
- **电转化**——短电脉冲让细菌膜暂时通透, 质粒 DNA 进入。

循环结构

The 48-hour Active-Learning Cycle / 48 小时主动学习循环



湿实验室 → 干实验室对接

每轮结束，湿实验室提交到 `08_cycle_data/outputs/cycle_<N>/:`

文件	必需列
<code>elisa_processed.csv</code>	<code>variant_id</code> , <code>receptor_id</code> , <code>ec50_nM</code> , <code>hill_slope</code> , <code>r2</code> , <code>plate_id</code> , <code>date</code>
<code>plaque_results.csv</code>	<code>variant_id</code> , <code>strain_id</code> , <code>pfu_per_ml</code> , <code>date</code>
<code>qc_report.md</code>	SDS-PAGE 图像路径、浓度、表达备注

重训最低门槛：每个 `variant` ≥ 3 个有效 `EC50` 且 $R^2 > 0.9$ 。失败 `variant` 标记 `ec50_nM = NaN + failed_reason` ——模型可处理缺失数据。

干实验室 → 湿实验室对接（48 小时 SLA）

收到 ELISA 数据后：

文件	用途
recommendations.csv	4 BALD + 1 随机；主要任务列表
primer_sequences.txt	NEB Q5 兼容的 SDM 引物
uncertainty_bands.png	校准图：上一轮 预测 vs 实测
safe_pick_backup.csv	Top-10 BALD，48 小时 SLA 未达时手动选择
run_meta.json	git SHA + 时间戳 + 池统计（溯源）

湿实验室**不知道**哪一行是随机对照——保留盲法基准，用于项目结束时的 AL vs random 事后比较。

Cloning 执行

- **Cycle 0** ——基因合成 (IDT/Twist), 4-6 个 variant, 基于结构设计。约 2 周交付, ~\$150/variant。
- **Cycle 1+** ——定点突变 (NEB Q5), 在已有构建体上做点突变。约 4 天, ~\$50/variant (3× 更便宜, 3.5× 更快)。
- BALD 在小数据场景下倾向选点突变 → SDM 是自然的执行方法。

载体: pET-28a (Addgene 69864-3)。宿主: BL21(DE3)。诱导: 0.5 mM IPTG, 18 ° C 过夜 (利于可溶 trimer 装配)。

ELISA 协议——全菌结合

来自 Boeckaerts 2024 + Latka 2021:

- 1 96 孔板包被热失活 *Xanthomonas* (10^8 CFU/孔)。
- 2 3 % BSA 封闭 1 h。
- 3 系列稀释 His6-RBP ($1\text{ nM} - 1\text{ }\mu\text{M}$)。
- 4 HRP-anti-His6 检测, TMB 显色, 读 OD_{450° 。
- 5 **4PL 拟合** → **EC50** 是主动学习的目标变量。

每板对照: BSA-only (背景); WT-RBP (板间归一化); 热变性 RBP (折叠特异性); 每个浓度 3 个技术重复。

受体敲除——pK18mobsacB (Schäfer 1994)

无标记敲除（自杀载体 + 蔗糖反选）：

- 1 构建敲除质粒：靶基因上下游各约 500 bp + pK18mobsacB。
- 2 电转入 Xcc 分离株；卡那霉素正选（单交换）。
- 3 蔗糖反选（sacB 致死非解离体）；PCR 确认。

靶基因（基于 Hung 2003）：

- Δ tonB、 Δ exbB、 Δ exbD1 → 预期**阻断** phiL7 感染。
- Δ exbD2 → 预期**保留**感染（内置阴性对照）。

时间线：每个基因 4-6 周（可并行）。

验证层次

层次	测什么	故事
1	仅 ELISA (WT 宿主)	” 我们找到了结合更好的 variant。”
2	+ Plaque 测定 (WT)	” 结合 → 感染已确认。”
3	+ ΔtonB / ΔexbB / ΔexbD1	” 受体特异性因果” (论文级)。

建议 (PI 简报): 若 5/17 启动敲除, 承诺第三层。 ΔexbD2 阴性对照免费验证整个敲除系统。

质量门与失败模式

失败	处理
干实验室未达 48-h SLA Variant 不溶解 ELISA R ² < 0.9 5 个 pick 全部 QC 失败 Calibration ECE > 0.1	湿实验室使用 <code>safe_pick_backup.csv</code> 标 NaN; 尝试备用 truncation 重训时下调权重 1 个专家选 + 2 个随机; 用部分数据重训 下次 BALD 前做 temperature scaling

第 6 部分——复现与演示 · [干实验室] [湿实验室]

本部分关键术语

- **分支 (branch)** ——git 历史的平行线。代码全在 `active-learning-pipeline`; `main` 故意留空。
- **Conda 环境** ——固定版本的 Python 安装。运行任何命令前先 `conda activate igem2026`, 否则会 `import` 失败。
- **pytest** ——Python 标准测试运行器。每个模块自带一小套测试; 通过 = 契约不破。
- **JupyterLab** ——浏览器内打开 `.ipynb` notebook 的界面。
- **Laguna (CARC)** ——USC 的 GPU 集群。跑笔记本电脑跑不动的活 (Boltz-2、ESM-2 650M、AF3)。
- **SLURM** ——Laguna 的任务调度器。`sbatch script.slurm` 提交给空闲 GPU 节点。
- **CUDA** ——Nvidia GPU 计算平台。固定 `CUDA 12.1 / torch==2.5.1+cu121` 以匹配集群驱动。

快速开始

```
# 克隆 + 切分支
git clone https://github.com/Alex-Ch3n/iGEM_Claremont_2026.git
cd iGEM_Claremont_2026
git checkout active-learning-pipeline

# 环境 (一次性)
conda env create -f shared/env/environment.yml
conda activate igem2026
pip install nbstripout && nbstripout --install

# 本地开发最小基因组 (共约 5 MB)
python 00_raw_data/processes/fetch_phages.py --accession EU717894.1
python 00_raw_data/processes/fetch_phages.py --accession NC_001604.1
python 00_raw_data/processes/fetch_bacteria.py --accession GCF_000007145.1

# 启动 JupyterLab
jupyter lab
```

完整逐模块清单: GETTING_STARTED.md。

每个模块的入口

Module	从这里打开
00	00_raw_data/processes/01_verify_dataset.ipynb
01	01_data_ground_truth/processes/01_fetch_reference_genomes.ipynb
02	02_annotation/processes/01_run_phanotate.ipynb
03	03_rbp_identification/processes/01_run_phagerbpdetect.ipynb
04	04_protein_embedding/processes/01_embed_esm2.ipynb
05	05_structure_prediction/processes/01_run_boltz2.ipynb (生产用 Laguna)
06	06_uncertainty_model/processes/run_cycle0.py
07	07_acquisition_function/processes/run_bald.py

输出文件位置

文件	路径（相对仓库根）
相互作用矩阵	01_data_ground_truth/outputs/interaction_matrix.csv
RBP 候选	03_rbp_identification/outputs/EU717894.1_rbp_candidates.csv
ESM-2 embedding	04_protein_embedding/outputs/embeddings_esm2_t6_8M_phiL7_rbps.npz
Boltz-2 PDB / ipTM	05_structure_prediction/outputs/boltz2/EU717894.1_rbp_01__GCF_000007145.1_tonB/
集成预测	06_uncertainty_model/outputs/cycle_0/predictions.csv
校准图	06_uncertainty_model/outputs/cycle_0/calibration.png
BALD 推荐	07_acquisition_function/outputs/cycle_1/recommendations.csv
PAE 热图	pae_heatmap.png（仓库根）

现场演示计划（完整 runbook → DEMO.md）

- 1 **Module 03** —— `pytest 03_rbp_identification/processes/tests/ -v` (~15 s)。
- 2 **Module 04** —— 检查已缓存的 `.npz` (`shape (3, 320)`, `seq_ids` 对应 `rbp_01/02/03`) (<1 s)。
- 3 **Module 06** —— `python 06_uncertainty_model/processes/run_cycle0.py` (~3 s, 已验证)。
- 4 **Module 07** —— `python 07_acquisition_function/processes/run_bald.py --cycle 1 --n_bald 4 --n_random 1` (<1 s)。
- 5 **Module 05 (只读)** —— 打开 `pae_heatmap.png` 与 PDB (PyMOL)。

每步都有”说什么”和”失败怎么办”，见 DEMO.md。

Laguna HPC ——何时切换到 GPU

任务	本地?	为什么 Laguna?
ESM-2 8M (3 个 RBP)	是	CPU 秒级
ESM-2 650M / 3B (777 phages)	否	GPU 显存 + 时间
Boltz-2 蛋白-蛋白	否	约 15 分钟/对, 仅 A100/L40S
AF3 batch	否	GPU + 权重审批
集成训练 + BALD	是	CPU 秒级

环境配方 + SLURM 模板: `LAGUNA.md` (CUDA 12.4, torch 2.5.1+cu121)。

测试——当前通过率

Module	测试
00 原始数据	15+ 通过 (3 个预期失败——GCF/T7 不在 seed list)
01 Ground Truth	22/22
02 注释	26/26
03 RBP ID	25+ 通过 (2 个预期失败——HMM 需要本地 hmmpress)
04 Embedding	17/17
05 结构	28/28 (1 个预期跳过——需要完成的 GPU 跑)
06 不确定性	9/9
07 BALD	18/18

第 7 部分——风险、决策与请求 · [PI]

待 PI 决策事项

决策	截止	默认
敲除系统 pK18mobsacB vs CRISPRi AlphaFold 3 权重——谁去申请？ 验证层次承诺 LA 县噬菌体富集来源 论文投稿意向	5/17 本周 6/1 前 6/1 前 Cycle 0 前	pK18mobsacB (Hung 2003 在 Xcc 上已用过) Alex 或 PI; 学术机构 email 优先 第三层 (若 5/17 启动敲除) 待定——需 PI 实验室渠道 与 iGEM wiki 并行投 Bioinformatics / NAR Genomics

关键风险与缓解

风险	可能性 / 影响	缓解
菌株分离失败	低 / 高	双源 (十字花科 + 柑橘); 2 轮采样
噬菌体分离无裂解性	中 / 高	污水 / 农业径流富集; Phage Directory 备用
RBP 表达不溶解	中 / 中	先用 T7 gp17 阳性对照; GCN4 trimer tag 备选
ELISA 动态范围不足	中 / 高	Cycle 0 前 2 周专门优化 ELISA
AL 不如随机	低 / 高 (可报告)	标准对照臂; 诚实报告
干实验室未达 48-h SLA	中 / 中	PI 预批的 <code>safe_pick_backup.csv</code>
受体敲除失败	中 / 中	多靶基因并行; CRISPRi 备用

“AL 不如随机” 的样子

- 在 Cycle 2 后: BALD 轨迹的测试集 $R_{\square}$ 与随机选择**统计等价**。
- 我们承诺诚实报告:
 - 用与正面结果同等严谨度记录该负面结果。
 - 对领域是有用贡献——Hie 2024 行, ALDE 行, phage-RBP (暂时) 不行。
- 每轮归档的具体指标:
 - 测试集 $R_{\square}$ (在 held-out variant 上)。
 - Calibration ECE。
 - 每次实验的信息增益 (后验 vs 先验 KL 散度)。

时间线

日期	里程碑
2026-05-17	湿实验室启动：十字花科采样、pK18mobsacB 构建、Cycle 0 合成订单
2026-06-01	Cycle 0 启动：ELISA 优化 + 首批结合测量
2026-06-14	Cycle 1：集成重训，首批 BALD picks, SDM
2026-06-28	Cycle 2：第二轮，受体敲除完成
2026-07-12	分析与拓展：训练模型应用于土壤源噬菌体基因组
2026-09-12	Wiki 冻结准备
2026-10-21	Wiki 冻结
2026-11-13	Grand Jamboree

iGEM 交付物清单

- **Wiki:** Engineering DBTL · Modeling · Hardware/Software · Human Practices。
- **Composite Part:** $\geq 4-6$ 个 RBP-His6 构建体（来自自分离噬菌体）。
- **软件仓库:** 开源闭环 AL pipeline（即本仓库）。
- **宣传视频:** 一个闭环周期的演示。
- **社区贡献:** 自分离 Xanthomonas + 噬菌体 $\rightarrow$ iGEM Registry; 测序基因组 $\rightarrow$ NCBI。

给团队的开放性问题

- 1 湿实验室——LA 县的污水 / 农业径流渠道？
- 2 湿实验室——在投 variant 库前是否先做 T7 gp17 阳性表达对照？
- 3 干实验室——谁负责 ESM-2 3B Laguna 任务（1280 → 2560 维，最终基准）？
- 4 全员——论文投稿与 iGEM wiki 冻结的时间关系？
- 5 PI ——若分离株鉴定结果是检疫级 pathovar，APHIS 许可的姿态？

第 8 部分——参考文献与附录

各模块关键论文——紧凑表

Module	论文	角色
00 / 01	da Silva 2002 Nature; Lee 2009 AEM; Hung 2003 BBRC	参考基因组 + 受体
02	McNair 2019 Bioinformatics (PHANOTATE); Hyatt 2010 (Prodigal); Bouras 2023 (pharokka)	基因预测
03	Boeckaerts 2022 Viruses (PhageRBPdetect)	RBP HMM + XG
04	Lin 2023 Science (ESM-2); Liu 2025 Nat Commun (PLM-interact)	embedding + PF
05	Abramson 2024 Nature (AF3); Passaro 2025 (Boltz-2)	结构 + ipTM
06	Lakshminarayanan 2017 NeurIPS; Greenman 2025 PLoS Comput Biol	深度集成 + UQ 核
07	Houlsby 2011 (BALD); Yang 2025 Nat Commun (ALDE); Hie 2024 Nat Biotechnol	采集
08	Sch�fer 1994 (pK18mobsacB); Gibson 2009; Latka 2021 mBio	湿实验室方法

完整带注释阅读指南: docs/reference/papers.md (19 篇)。

五项文献核查修正（2026 年 5 月）

原说法	修正后
" TonB-ExbB-ExbD1-ExbD2 全必需" (Wang 2003)	TonB-ExbB-ExbD1 必需; ExbD2 不是 (Hung 2003 BBRC)
" Boltz-2 affinity head 用于 RBP × 受体"	affinity head 仅小分子 → NaN; 用 ipTM
" Greenman 2025 NAR Genomics; 深度集成最佳 UQ"	Greenman 2025 PLoS Comput Biol; " 无单一最佳 UQ"
" Hie 2024 用 ESM-2, 约 50 个抗体 variant"	Hie 2024 用 ESM-1b/1v, 每个抗体 20 个 variant
" Lee 2009 命名了 tail spike"	Lee 2009 主动搜索并找不到 OP1 ORF25 同源物

完整核查: docs/reference/paper_reading_notes.md。

导航参考

想知道……	看这里
每个模块的产出	<module>/README.md
端到端状态快照	docs/planning/PI_briefing_2026-05-11.md
项目计划 (EN)	docs/planning/iGEM_2026_Project_Plan.md
项目计划 (ZH)	docs/planning/iGEM_2026_ 项目大纲 _ 中文版.md
论文列表 (注释)	docs/reference/papers.md
文献修正记录	docs/reference/paper_reading_notes.md
数据约定	INTERFACE.md
HPC 设置	LAGUNA.md
湿实验室 SOP	docs/protocols/ (5 份 Benchling PDF)

术语表——快速查询

术语	含义
RBP	Receptor-binding protein ——噬菌体的” 钥匙”
HMM	Hidden Markov Model ——序列 profile 方法
ESM-2	进化尺度蛋白语言模型 (Lin 2023)
ipTM	Interface predicted TM-score (0-1, 结构信心)
ELISA	酶联免疫吸附测定 (结合读数)
EC50	半数有效浓度 (4PL 拟合)
SDM	定点突变 (NEB Q5 试剂盒)
BALD	Bayesian Active Learning by Disagreement (Houlsby 2011)
Epistemic	可约的模型不确定性 (= BALD 目标)
Aleatoric	不可约的测量噪声

完整术语表: <docs/reference/glossary.md>。

引用清单——受体生物学 + Xanthomonas 病理

- 1 **da Silva 2002** ——Nature 417:459-463。Xcc ATCC 33913 参考基因组 (GCF_000007145.1 / GenBank AE008922)。
- 2 **Lee 2009** ——Appl Environ Microbiol 75(24):7828-7838。phiL7 基因组 (NCBI EU717894)。审计：主动搜索却找不到 OP1 ORF25 tail-fiber 同源物。
- 3 **Hung 2003** ——BBRC 302(4):878-884, PMID 12646254。TonB / ExbB / ExbD1 是 phiL7 必需；ExbD2 不必需。审计：此前引用的“Wang 2003”为幻觉文献。
- 4 **Ryan 2011** ——Nat Rev Microbiol 9:344-355。>400 种宿主范围；经济背景。
- 5 **Aiello 2019** ——Plant Dis。Xanthomonas 的铜抗性。
- 6 **Iriarte 2018** ——Front Plant Sci 9。番茄上的噬菌体生物防治田间试验。
- 7 **Holtappels 2022** ——Microb Biotechnol 15(3):597-610。噬菌体在整合植物保护中。
- 8 **Farquharson 2021** ——T4 × E. coli: 结合 ≠ 感染 (RBP 结合 85 % 菌株, 仅 11 % 形成噬斑)。

引用清单——宿主范围预测 + 基因组注释

- 9 **Boeckaerts 2022** ——Viruses 14(6):1329。PhageRBPdetect HMM + XGBoost (precision-recall AUC 93.8 %, F1 84.0 %)。
- 10 **Boeckaerts 2024** ——Nat Commun 15:4768/48675。PhageHostLearn (菌株级)。**审计:** AUC “0.82” 的准确说法是 100 % identity threshold 下 up to 81.8 %; 跨菌株降到约 0.70。
- 11 **Mutalik 2025** ——bioRxiv (预印本)。PAML benchmark: 跨菌属 AUC 0.67-0.70。
- 12 **McNair 2019** ——Bioinformatics 35(22):4537-4542。PHANOTATE (用动态规划处理重叠 ORF)。
- 13 **Hyatt 2010** ——BMC Bioinformatics 11:119。Prodigal (通过 pyrodigal 调用)。
- 14 **Bouras 2023** ——Bioinformatics 39(1):btac776。Pharokka 噬菌体注释流程。

引用清单——蛋白语言模型、结构、UQ

- 15 **Lin 2023** ——Science 379(6637):1123-1130。ESM-2 (约 65 M 序列; 650M → 1280 维, 3B → 2560 维)。
- 16 **Liu 2025** ——Nat Commun 16:64512, DOI 10.1038/s41467-025-64512-w。PLM-interact PPI 迁移 (AUPR +16-28 %)。
审计: 未在噬菌体-细菌上测试。
- 17 **Abramson 2024** ——Nature 630:493-500, DOI 10.1038/s41586-024-07487-w。AlphaFold 3。
- 18 **Passaro 2025** ——bioRxiv (预印本)。Boltz-2。审计: affinity head 只支持小分子 (PubChem / ChEMBL / BindingDB), 对蛋白-蛋白对输出 NaN。用 ipTM 作结构信心 proxy。
- 19 **Lakshminarayanan 2017** ——NeurIPS 30, arXiv:1612.01474。深度集成 + Gaussian NLL。
- 20 **Ovadia 2019** ——NeurIPS 32。在分布漂移下评估 UQ。
- 21 **Greenman 2025** ——PLoS Comput Biol 21(1):e1012639, DOI 10.1371/journal.pcbi.1012639。审计: 期刊是 PLoS Comput Biol (不是 NAR Genomics); 结论是“无单一最佳 UQ 方法”。

引用清单——主动学习 + 湿实验室方法

- 22 Lindley 1956** ——Ann Math Stat 27:986-1005。贝叶斯最优实验设计。
- 23 Settles 2009** ——CS Tech Rep 1648, U. Wisconsin-Madison。Active Learning Literature Survey。
- 24 Houlisby 2011** ——arXiv:1112.5745。BALD。审计：原文是 GPC 分类；深度集成回归是我们的延伸。
- 25 Hie 2024** ——Nat Biotechnol 42:275-283 (预印 2022)。审计：使用 ESM-1b/1v (不是 ESM-2)；每抗体约 20 variant；语言模型 likelihood 过滤，非 BALD 闭环。早期文档中的“Hie 2022 Cell”指同一篇。
- 26 Yang 2025** ——Nat Commun 16:55987, DOI 10.1038/s41467-025-55987-8。ALDE。审计：用 Thompson 采样 + one-hot (不是 BALD + ESM-2)。
- 27 Wittmann 2021** ——Cell Syst 12(11):1026-1045。ML 辅助定向进化；exploration vs exploitation。
- 28 Scherfer 1994** ——Gene 145(1):69-73。pK18mobsacB (Addgene #87097)。
- 29 Gibson 2009** ——Nat Methods 6:343-345。Gibson 组装。
- 30 Studier & Moffatt 1986** ——J Mol Biol 189(1):113-130。pET / BL21(DE3) 表达系统。
- 31 Latka 2021** ——mBio 12(6):e02329-21。RBP 模块化 truncation。审计：解聚酶机制；结构原则可迁移，生化机制不可。

文档日志

日期	改动
2026-05-17	初稿：约 71 张 slide + 配套 guide + DEMO + 4 张图。Pandoc + Beamer + xelatex + xeCJK / Hiragino Sans GB。
2026-05-17	路径核查；演示计划加入 Module 04 (slide 48 + DEMO.md)；修正 phage_genomes/ → phage/<acc>/；HMM 通过 setup_inputs.sh 准备。提交为 5304f69。
2026-05-18	第 1-6 部分开头加入”本部分关键术语” slide（第 3 部分两张——神经网络基础 + UQ/AL）。与 guide_zh.md 中相应 callout 对齐。
2026-05-18	顺手修正：“Hie 2022” → “Hie 2024”（同一篇）。新增 4 张引用清单（31 条含审计说明）与本日志。

全部由 Claude（入职 agent）撰写，Alex Chen 审阅。完整版日志见 docs/onboarding/guide_zh.md。

谢谢 / Thank you

欢迎提问、评论、质疑。

- 干实验室: Alex Chen —CChen29@cmc.edu
- PI: Prof. J. Cesar Ignacio-Espinoza
- 学术顾问: Prof. Ran Libeskind-Hadas
- 湿实验室负责人: Sarah、Olivia、Weitao、Carol
- 贡献者: Ryan、Leah

接下来现场演示 (15 分钟), 见 docs/onboarding/DEMO.md。